Análisis integral: diagnóstico de cáncer de mama

Calidad, exploración, hallazgos y evaluación predictiva académica

Tabla de contenidos

1 1. Objetivo y alcance **2**
1.1 Cómo avanza el análisis . . . 2

2 2. Carga y contrato de calidad **3**

3 3. Descripción del diagnóstico y las mediciones **5**

4 4. Exploración supervisada en entrenamiento **6**
4.1 Distribuciones por familia: promedio frente a peor valor . . . 6
4.2 Separación estandarizada de las mediciones promedio . . . 9
4.3 AUROC univariado: discriminación de una medición aislada . . . 10

5 5. Exploración de redundancia y estructura multivariable **10**

6 6. Exploración multivariable: PCA e importancias condicionadas **14**
6.1 Componente principal . . . 14
6.2 PCA frente a Elastic Net ante redundancia . . . 16

7 7. Proceso principal: contrastar representaciones **17**

8 8. Proceso principal: comparación de algoritmos **18**
8.1 Zoom para inspeccionar el área concentrada . . . 20
8.2 Ajuste y elección del campeón en entrenamiento . . . 22

9 9. Hallazgos y conclusiones **23**
9.1 Hallazgos sobre los datos . . . 23
9.2 Hallazgos sobre estructura y representación . . . 24
9.3 Conclusión predictiva . . . 24

9.4 Renderizado 25

```
- The project is out-of-sync -- use `renv::status()` for details.
```

1 1. Objetivo y alcance

Este documento estudia las mediciones de núcleos celulares extraídas de imágenes digitalizadas de aspirados con aguja fina (FNA) de masas mamarias. La unidad de análisis es una masa mamaria; el resultado observado es `diagnosis`: **M** (maligno) o **B** (benigno).

El propósito es producir evidencia reproducible sobre calidad, estructura y patrones de los datos, seguida de una evaluación predictiva académica. No es un instrumento clínico, no identifica causas y no debe utilizarse para diagnosticar pacientes.

Aspecto	Definición
Fuente	`data/data.csv` suministrado con el proyecto; dataset Breast Cancer Wisconsin (Diagnostic)
Cobertura observada	569 masas mamarias y 30 medidas numéricas
Target	Diagnóstico B/M
Momento de disponibilidad supuesto	Las 30 mediciones FNA están disponibles al evaluar la masa
Limitaciones	No hay fecha, demografía, tratamiento, procedencia clínica ni validación externa

1.1 Cómo avanza el análisis

El informe separa deliberadamente dos tipos de trabajo. La **exploración** describe patrones y formula hipótesis; no elige el modelo ni consulta la prueba. El **proceso principal** toma decisiones reproducibles únicamente con el conjunto de entrenamiento y validación cruzada. Esta distinción evita convertir un hallazgo visual en una conclusión predictiva.

Etapa	Tipo	Pregunta que responde	Qué habilita después
Calidad y partición	Proceso principal	¿La fuente es utilizable y qué datos quedan realmente reservados?	Trabajar sin imputación ni deduplicación y bloquear la prueba.

Etapa	Tipo	Pregunta que responde	Qué habilita después
Distribuciones, tamaños de efecto y AUROC aislado	Exploración	¿Qué diferencias y solapamientos se observan en entrenamiento?	Formular hipótesis sobre señal individual.
Correlación, PCA e importancias exploratorias	Exploración	¿Hay redundancia o estructura multivariable que convenga poner a prueba?	Comparar representaciones con y sin reducción, no decidir por una gráfica.
Ablación de representación	Proceso principal	¿`mean`, `mean + worst`, todas las variables o PCA generalizan mejor en CV?	Fijar la representación para la comparación de algoritmos.
Comparación, ajuste y prueba final	Proceso principal	¿Qué enfoque mantiene sensibilidad sin un coste desproporcionado?	Elegir un campeón por CV y medirlo una sola vez en prueba.

2 2. Carga y contrato de calidad

La fuente se conserva intacta. Se detectó una columna completamente vacía () derivada del delimitador final del archivo; no contiene información y se excluye sólo de la vista analítica.

Control	Resultado
Filas de la fuente	569
Columnas de la fuente	33
Columnas vacías	
Filas tras vista analítica	569
Columnas tras vista analítica	32
Valores faltantes (vista analítica)	0
Filas duplicadas exactas	0
IDs duplicados	0

Variable	Faltantes
id	0

Variable	Faltantes
diagnosis	0
radius_mean	0
texture_mean	0
perimeter_mean	0
area_mean	0
smoothness_mean	0

Conclusión descriptiva. La vista analítica tiene 569 registros, 32 columnas y 0 valores faltantes. Hay 0 filas duplicadas exactas y 0 IDs repetidos. Por tanto, no se aplican imputación, deduplicación ni exclusión de registros.

Tabla 1: Partición estratificada bloqueada antes de la exploración guiada por diagnóstico

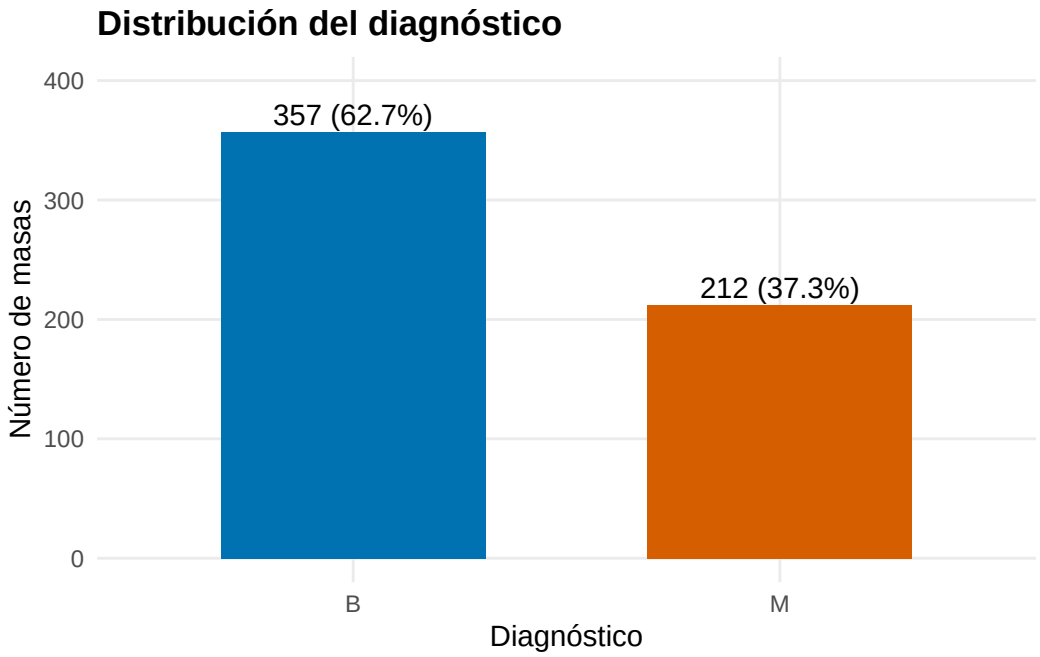
Conjunto	Diagnóstico	Casos	Proporción
M	169	Entrenamiento	0.372
B	285	Entrenamiento	0.628
M	43	Prueba reservada	0.374
B	72	Prueba reservada	0.626

Tabla 2: Cinco casos estadísticamente inusuales en entrenamiento

ID	Diagnóstico	Máximo |z| entre medidas
8710441	B	13.12
8810703	M	11.81
89143602	B	6.96
84501001	M	6.69
859711	B	6.62

Decisión del proceso principal. La prueba contiene 115 casos y queda bloqueada desde este punto. Los casos inusuales se mantienen porque no hay evidencia de un error de calidad; eliminarlos por ser extremos cambiaría la población sin justificación. No se usarán para seleccionar modelos.

3 3. Descripción del diagnóstico y las mediciones



Lectura del gráfico. Predominan los casos benignos (62.7%) frente a los malignos (37.3%). El desbalance es moderado, no extremo, pero una métrica de accuracy por sí sola podría ocultar errores en malignos; por ello la evaluación posterior prioriza sensibilidad y balanced accuracy.

Tabla 3: Siete variables con mayor dispersión absoluta

variable	media	mediana	sd	minimo	maximo
area_worst	880.583	686.50	569.357	185.200	4254.00
area_mean	654.889	551.10	351.914	143.500	2501.00
area_se	40.337	24.53	45.491	6.802	542.20
perimeter_worst	107.261	97.66	33.603	50.410	251.20
perimeter_mean	91.969	86.24	24.299	43.790	188.50
texture_worst	25.677	25.41	6.146	12.020	49.54
radius_worst	16.269	14.97	4.833	7.930	36.04

El conjunto contiene 357 masas benignas (62.7%) y 212 malignas (37.3%). Esta distribución hace necesario reportar sensibilidad y especificidad, no sólo exactitud global.

4 4. Exploración supervisada en entrenamiento

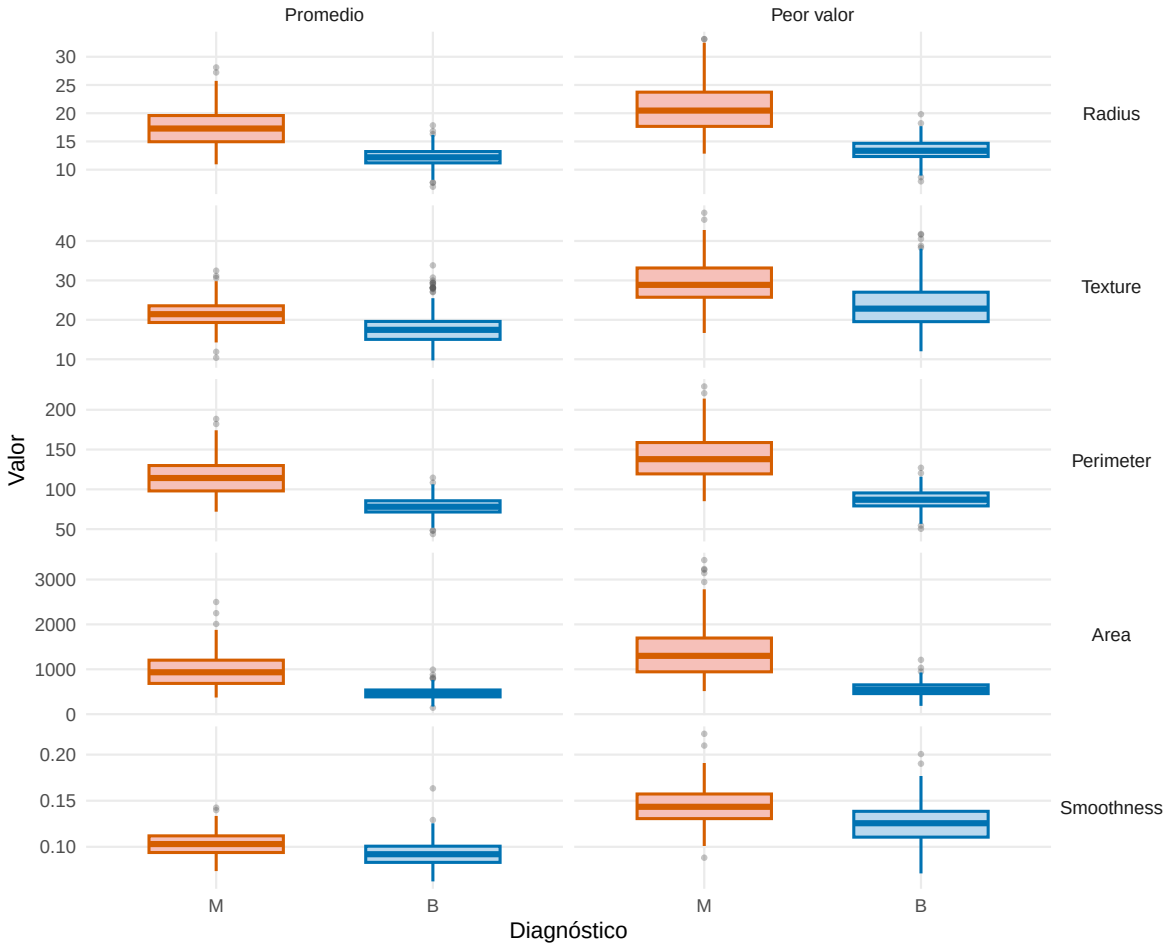
Esta sección es **exploratoria**: utiliza sólo el 80% de entrenamiento para evitar que la prueba influya en las hipótesis. Sus resultados describen asociaciones y solapamientos; todavía no seleccionan variables ni algoritmos.

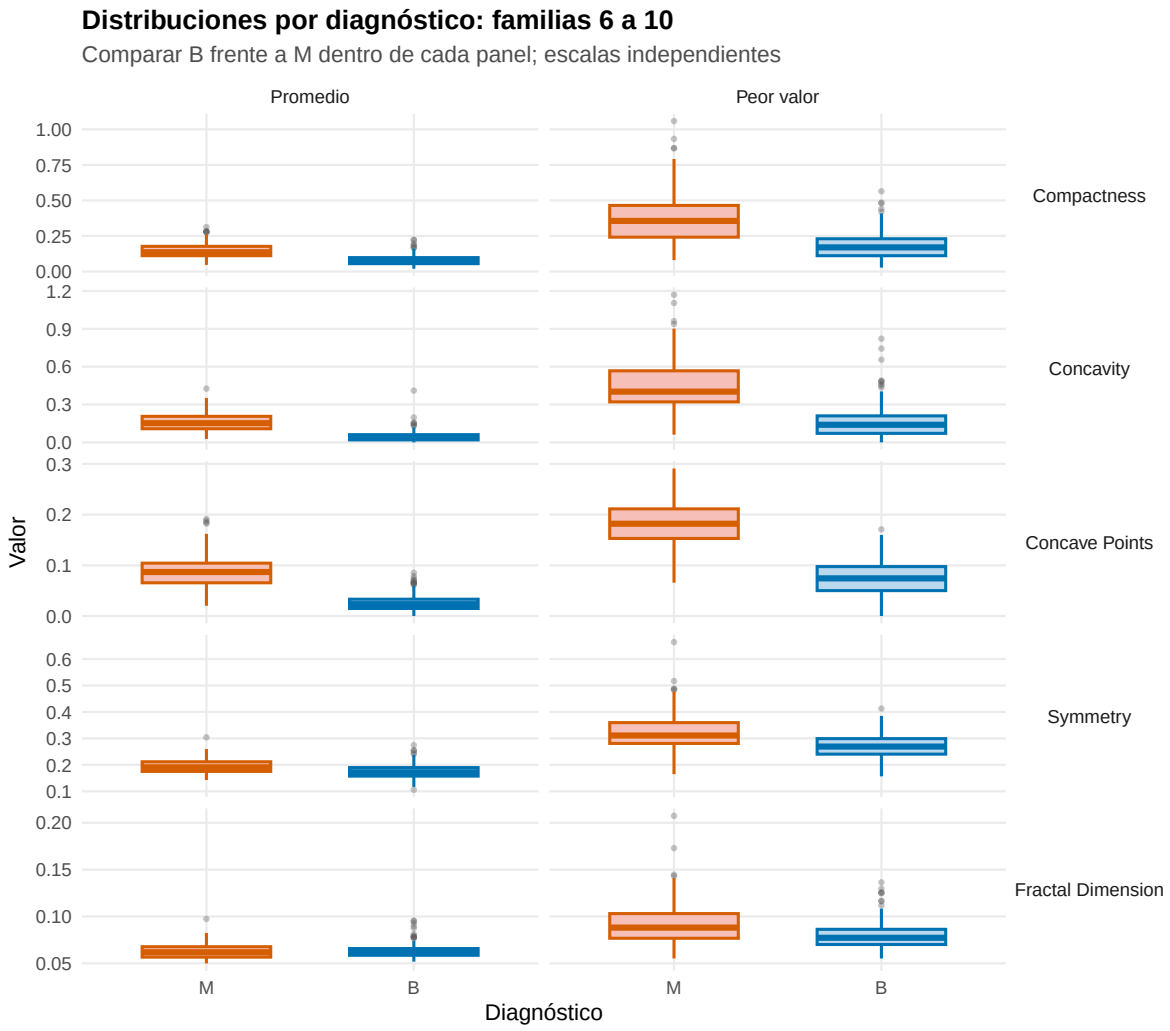
4.1 Distribuciones por familia: promedio frente a peor valor

Para evitar una selección arbitraria, se muestran las diez familias originales del conjunto de datos. Cada fila compara el resumen promedio (`mean`) con el promedio de los tres valores más altos (`worst`); los errores estándar (`se`) se excluyen de esta visualización para conservar una lectura centrada en nivel promedio y severidad. Las escalas son independientes por panel: la comparación válida es B frente a M dentro de cada panel, no la altura entre familias distintas.

Distribuciones por diagnóstico: familias 1 a 5

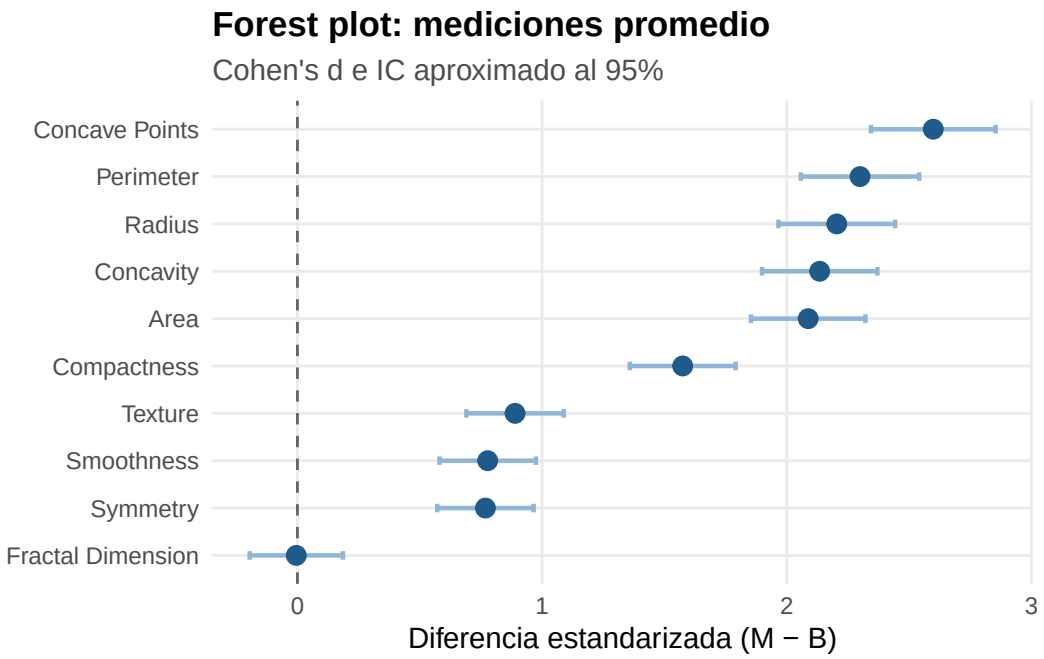
Comparar B frente a M dentro de cada panel; escalas independientes





Lectura de los boxplots. Las familias de tamaño e irregularidad muestran, en varios paneles, medianas más altas para M que para B, tanto en `mean` como en `worst`. Aun así hay solapamiento y observaciones extremas en ambos diagnósticos: las gráficas explican una señal grupal, no una regla determinista para cada masa ni una importancia predictiva independiente.

4.2 Separación estandarizada de las mediciones promedio

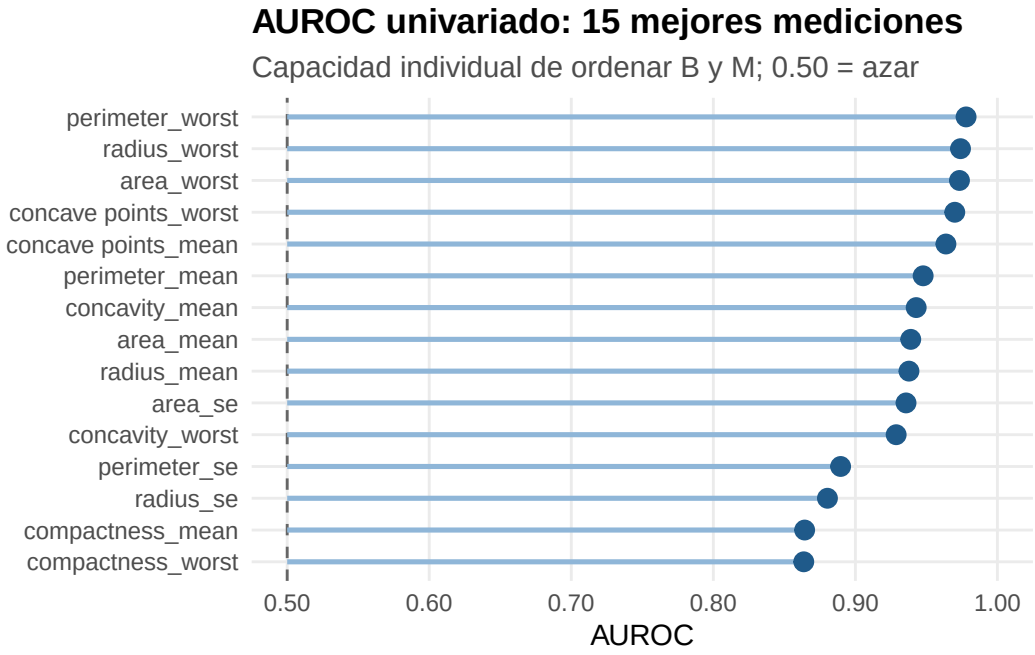


Medición promedio	Cohen's d	IC 95% inferior	IC 95% superior
Fractal Dimension	-0.005	-0.195	0.186
Symmetry	0.769	0.572	0.965
Smoothness	0.778	0.581	0.975
Texture	0.890	0.691	1.089
Compactness	1.575	1.358	1.791
Area	2.088	1.854	2.322
Concavity	2.135	1.899	2.370
Radius	2.205	1.966	2.443
Perimeter	2.299	2.057	2.542
Concave Points	2.599	2.344	2.854

Insight asociativo. Entre las mediciones promedio, Concave Points presenta la mayor diferencia estandarizada observada entre diagnósticos (M frente a B: 2.6 desviaciones estándar). El forest plot ordena las diez variables y añade intervalos de confianza aproximados. Esto justifica examinar señal individual, pero no demuestra causalidad ni permite descartar las otras variables.

4.3 AUROC univariado: discriminación de una medición aislada

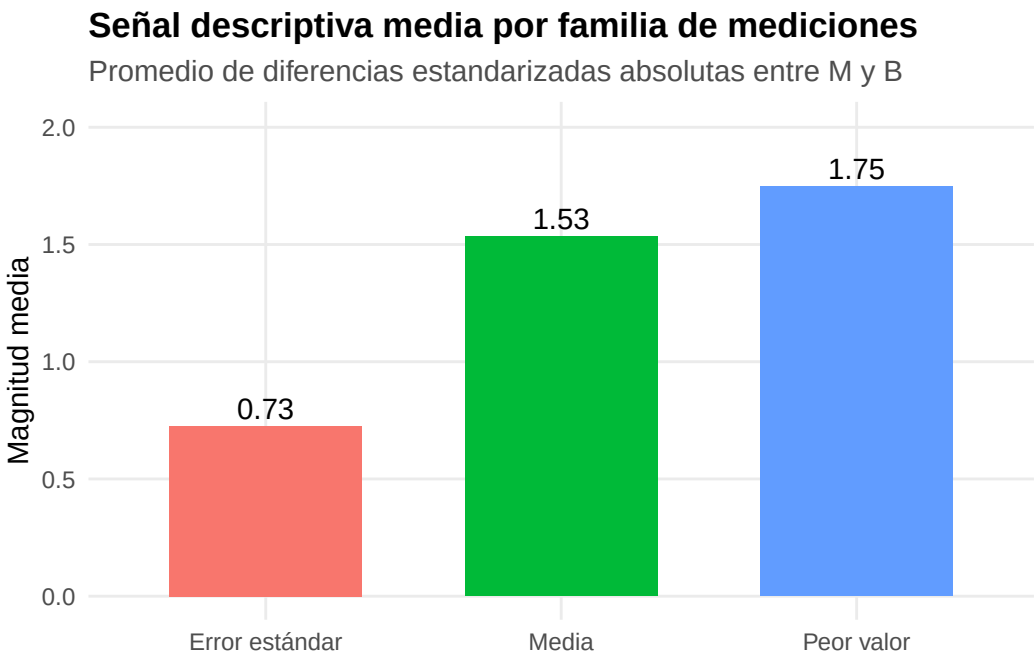
El AUROC univariado pregunta qué tan bien puede una sola medición ordenar casos malignos por encima de benignos, sin usar las demás variables. Un valor de 0.50 equivale a discriminación aleatoria; cuanto más se acerca a 1, mejor es su capacidad individual de ordenar los diagnósticos. Este cálculo y los siguientes modelos de importancia usan exclusivamente entrenamiento.

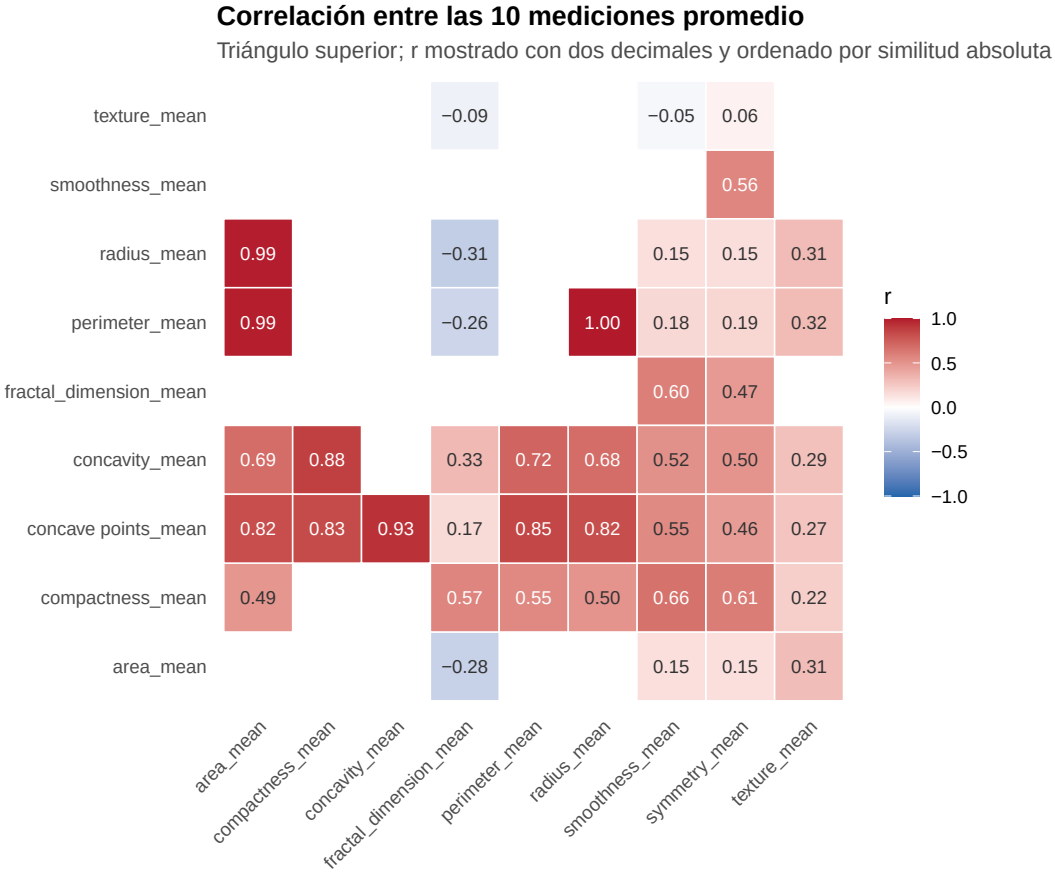


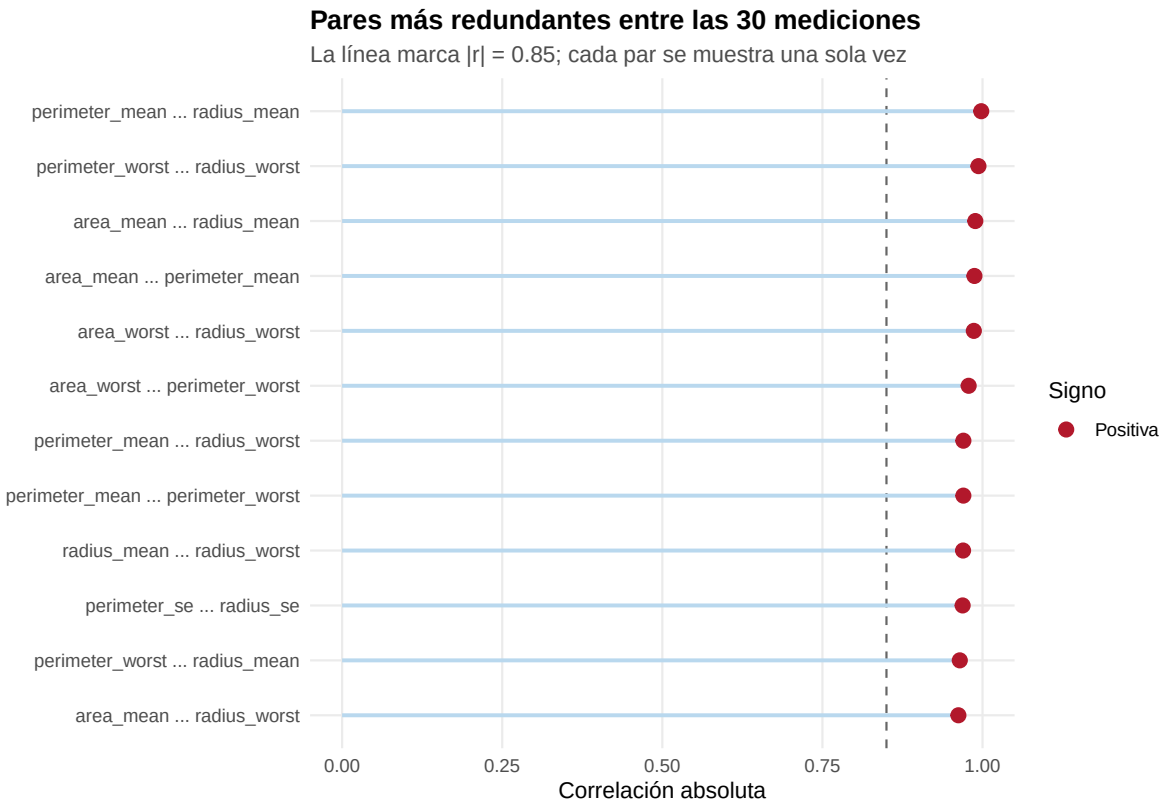
Resultado univariado. perimeter_worst logra el AUROC individual más alto (0.978) en entrenamiento. Esto identifica una medición prometedora aislada, pero no demuestra que conserve aporte independiente al combinarse con las demás.

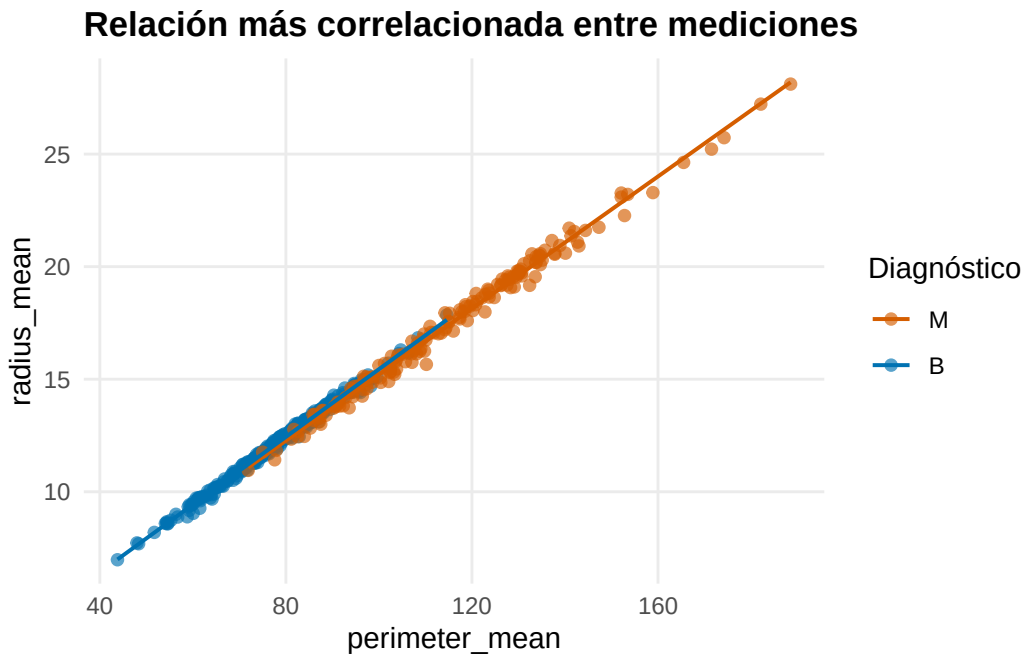
5 5. Exploración de redundancia y estructura multivariable

La señal aislada no basta para decidir qué variables conservar: dos mediciones pueden separar B/M y, aun así, transportar casi la misma información. Por eso se revisa la estructura conjunta de entrenamiento. Esta evidencia formula la hipótesis de que una representación compacta podría funcionar bien; no elimina columnas por una regla visual.


Señal descriptiva media por familia de mediciones
Promedio de diferencias estandarizadas absolutas entre M y B
Magnitud media
2.0
1.5
1.0
0.5
0.0
0.73
1.53
1.75
Error estándar
Media
Peor valor


Correlación entre las 10 mediciones promedio
Triángulo superior; r mostrado con dos decimales y ordenado por similitud absoluta
texture_mean
smoothness_mean
radius_mean
perimeter_mean
fractal_dimension_mean
concavity_mean
concave points_mean
compactness_mean
area_mean
−0.09
−0.05
0.06
0.56
0.99
−0.31
0.15
0.15
0.31
0.99
−0.26
1.00
0.18
0.19
0.32
0.60
0.47
0.69
0.88
0.33
0.72
0.68
0.52
0.50
0.29
0.82
0.83
0.93
0.17
0.85
0.82
0.55
0.46
0.27
0.49
0.57
0.55
0.50
0.66
0.61
0.22
−0.28
0.15
0.15
0.31
area_mean
compactness_mean
concavity_mean
fractal_dimension_mean
perimeter_mean
radius_mean
smoothness_mean
symmetry_mean
texture_mean
r
1.0
0.5
0.0
−0.5
−1.0

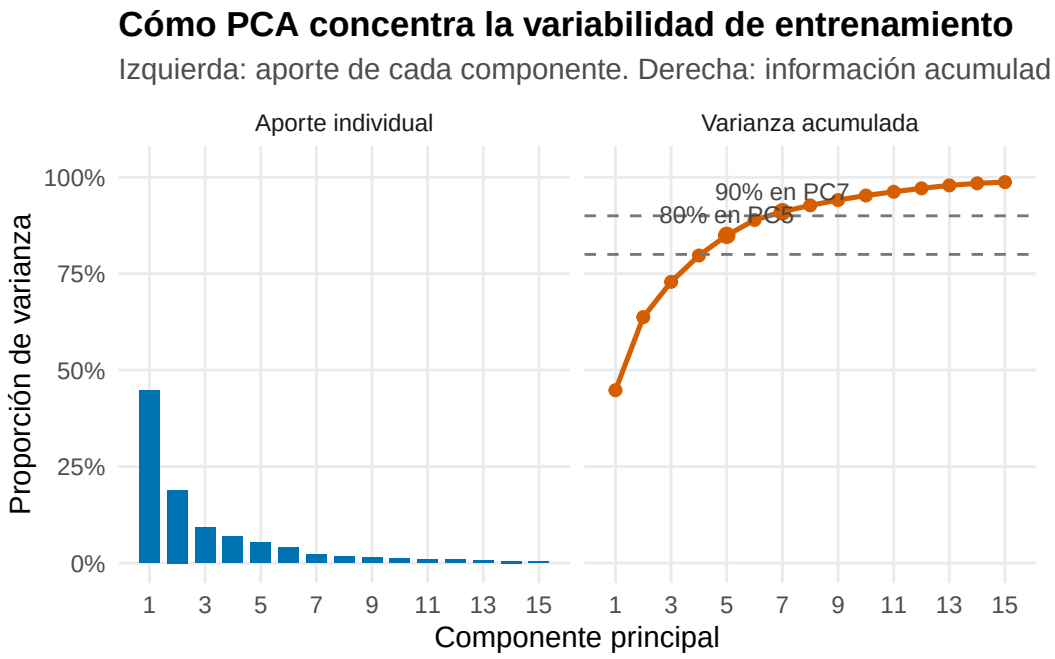

Pares más redundantes entre las 30 mediciones
La línea marca |r| = 0.85; cada par se muestra una sola vez
perimeter_mean ... radius_mean
perimeter_worst ... radius_worst
area_mean ... radius_mean
area_mean ... perimeter_mean
area_worst ... radius_worst
area_worst ... perimeter_worst
perimeter_mean ... radius_worst
perimeter_mean ... perimeter_worst
radius_mean ... radius_worst
perimeter_se ... radius_se
perimeter_worst ... radius_mean
area_mean ... radius_worst
0.00
0.25
0.50
0.75
1.00
Correlación absoluta
Signo
Positiva


Relación más correlacionada entre mediciones
radius_mean
25
20
15
10
40
80
120
160
perimeter_mean
Diagnóstico
M
B

Lectura por familia. La barra de **Peor valor** es la más alta (1.75): sus resúmenes muestran, en promedio, la mayor separación descriptiva B/M. Esto motiva contrastar la familia completa, pero no convierte a toda medición `_worst` en necesaria para todos los modelos.

Lectura de redundancia. La matriz triangular se limita a las diez mediciones `_mean` para interpretar las relaciones entre propiedades nucleares sin duplicar resúmenes derivados. El ranking conserva la evidencia completa: hay 28 de 435 pares entre las 30 mediciones con correlación absoluta de al menos 0.85. El par más intenso, perimeter_mean y radius_mean, alcanza 0.998. La redundancia no es un error: se probará formalmente si una reducción mantiene desempeño CV.

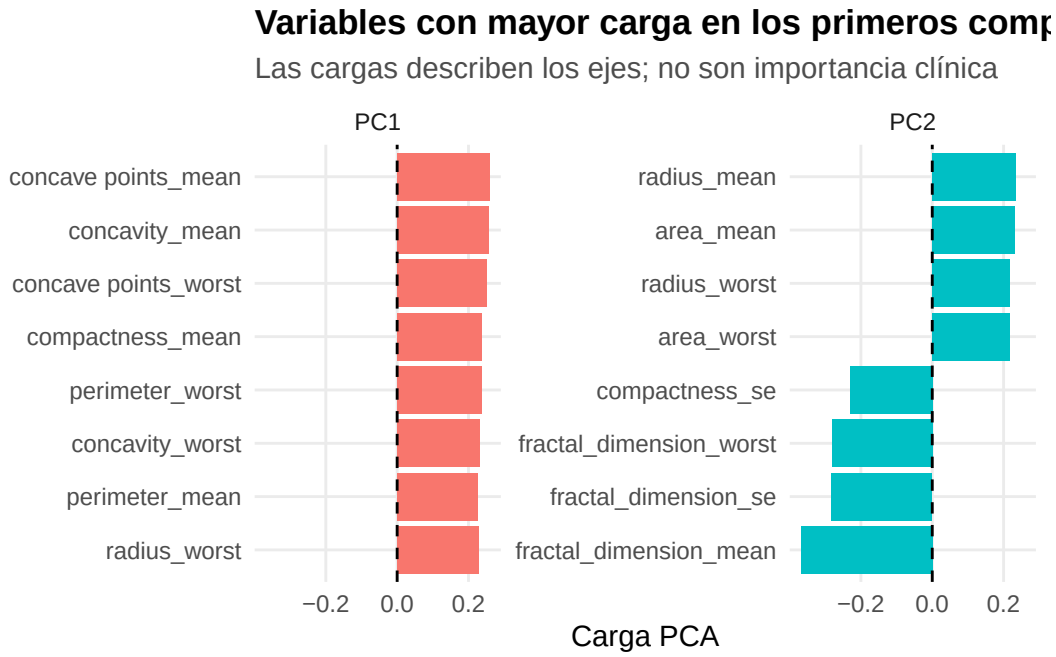
6 6. Exploración multivariable: PCA e importancias condicionadas

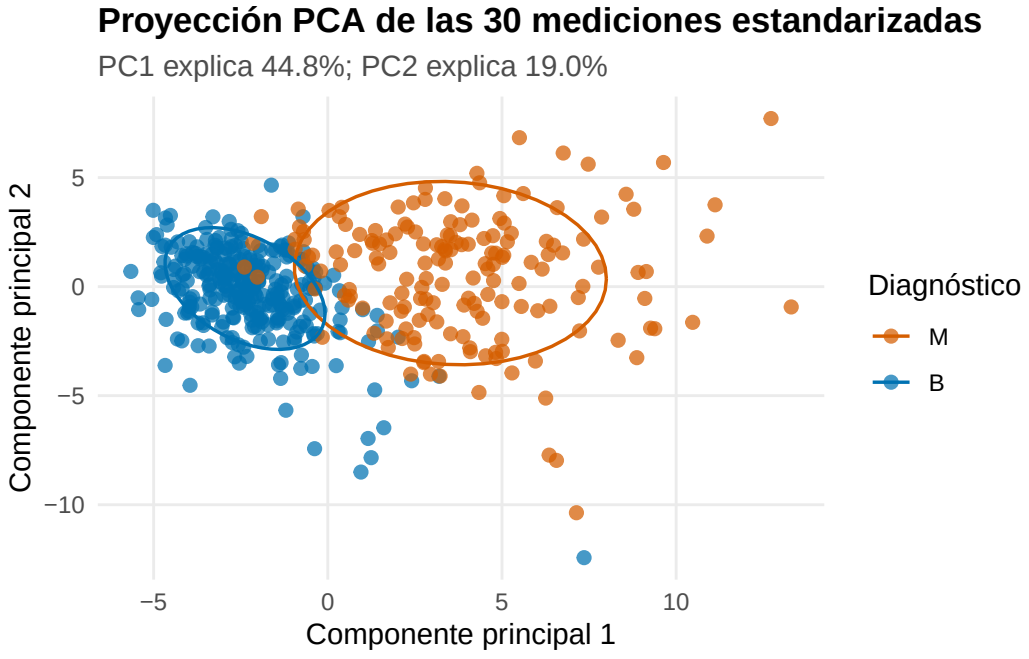


6.1 Componente principal

Un componente principal (`PC`) es una variable nueva construida como combinación lineal de las 30 mediciones originales estandarizadas; no corresponde a una medición clínica tomada directamente. `PC1` se construye para capturar la mayor cantidad posible de variabilidad total. `PC2` captura la mayor variabilidad que queda y es ortogonal a `PC1`, por lo que no repite su información lineal. El mismo criterio se aplica sucesivamente a `PC3`, `PC4` y los demás componentes.

Cada barra azul representa un componente individual y la proporción de variabilidad que aporta por sí solo. En la curva acumulada, que "90% se alcanza en PC7" significa que el conjunto formado por **PC1 hasta PC7** conserva aproximadamente 90% de la variabilidad de las 30 mediciones; no significa que `PC7` aislado explique 90%.

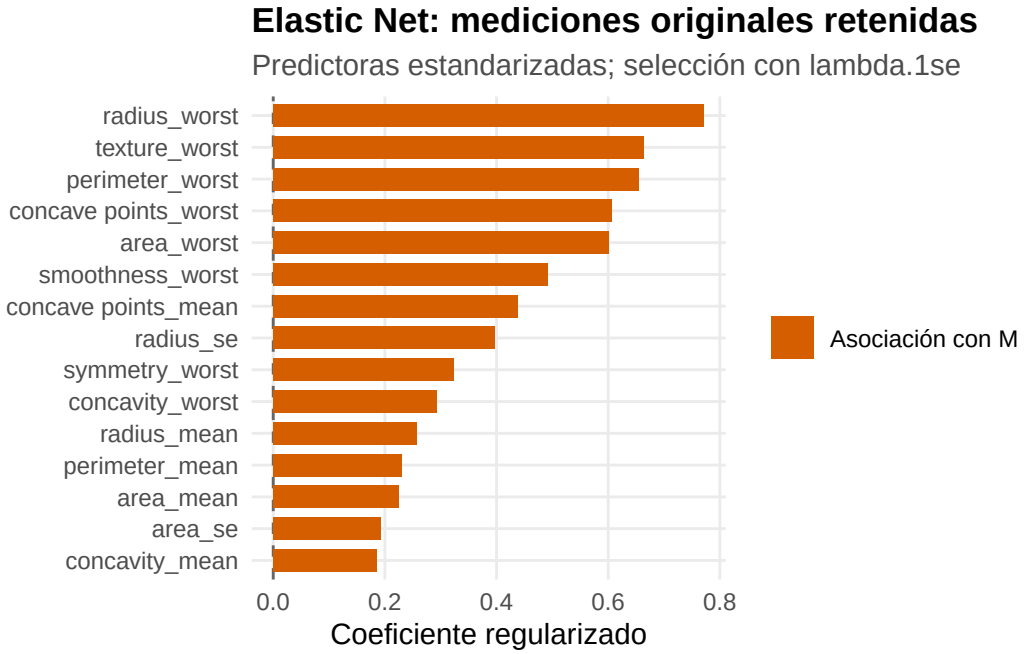




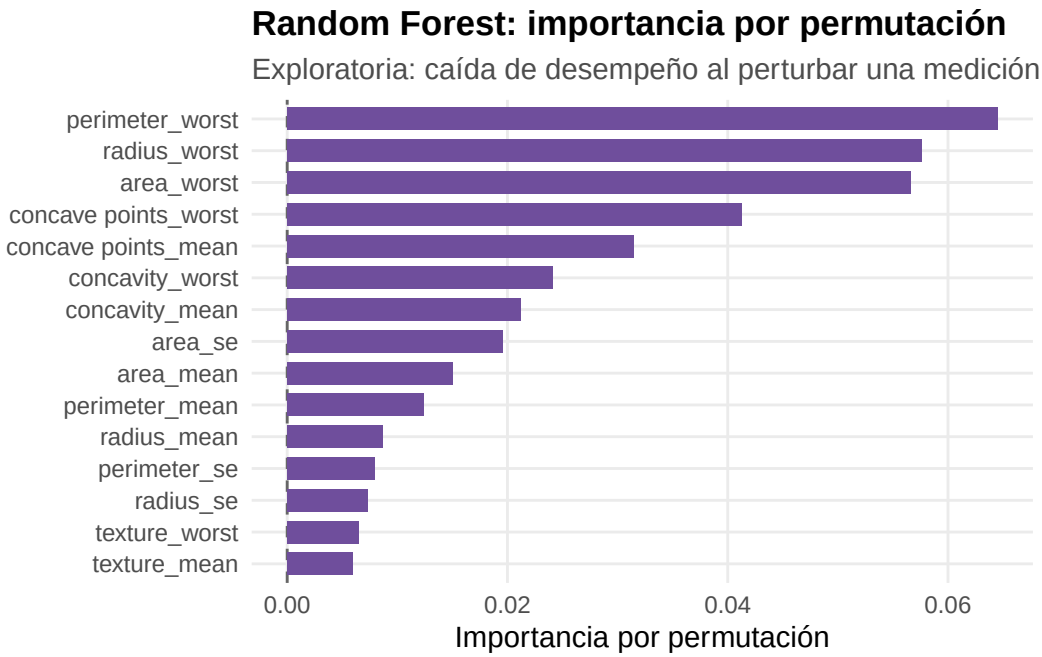
Lectura PCA. El panel izquierdo permite localizar el descenso del aporte individual; el derecho responde cuántos componentes se necesitan para conservar información: 80% se alcanza en PC5 y 90% en PC7. Los dos primeros componentes resumen 63.7% de la variabilidad estandarizada. Las cargas muestran qué medidas los construyen y la proyección revela separación parcial con solapamiento. Esto no demuestra clusters clínicos; PCA se evaluará después frente a las variables originales con las mismas particiones CV.

6.2 PCA frente a Elastic Net ante redundancia

PCA transforma las 30 mediciones en componentes nuevos y no elimina columnas originales. Elastic Net conserva las mediciones, pero encoge sus coeficientes y puede llevar algunos a cero. Ambos gráficos siguientes son exploratorios y usan únicamente entrenamiento; no intervienen en la selección final ni consultan la prueba reservada.



Resultado lineal penalizado. radius_worst tiene la mayor magnitud de coeficiente entre las mediciones mostradas. Elastic Net busca una representación lineal más compacta, reduciendo coeficientes de señales redundantes; un coeficiente alto indica aporte condicionado al resto de predictores, no causalidad ni importancia clínica automática. PCA resume patrones compartidos —por ejemplo, tamaño— en componentes nuevos; Elastic Net conserva nombres de variables originales. Ninguno sustituye la comparación validada de modelos.



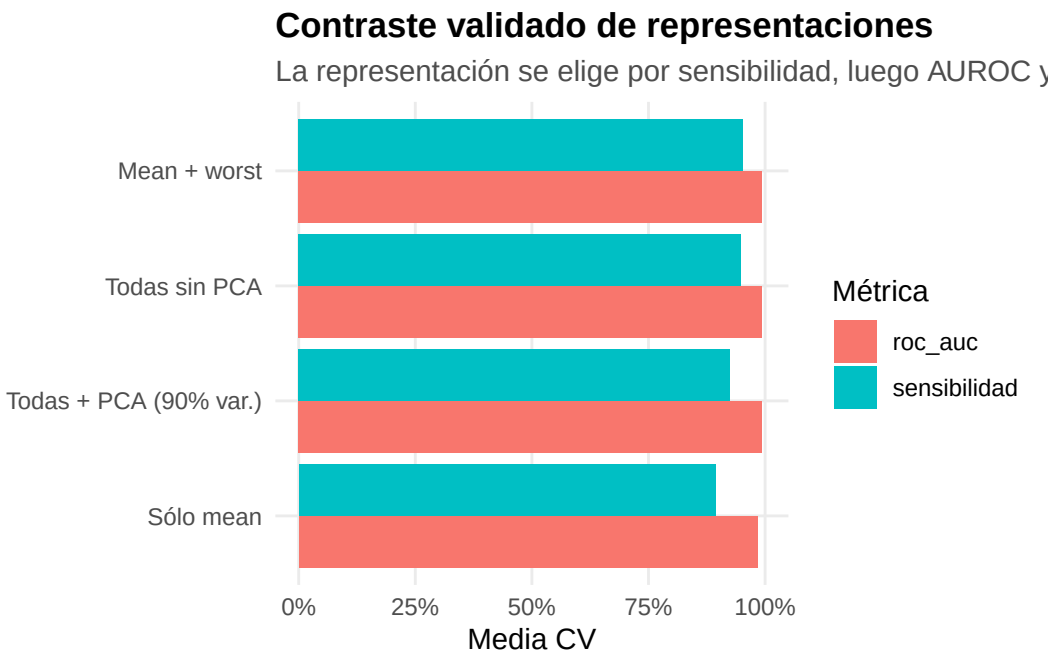
Lectura de importancias. Elastic Net muestra aportes lineales condicionados al resto y Random Forest busca aportes dentro de un ajuste no lineal. En presencia de correlación, ambos pueden repartir importancia entre sustitutos. Por ello sirven para interpretar hipótesis, no para seleccionar columnas de forma definitiva; la siguiente etapa contrasta representaciones completas con validación cruzada.

7 7. Proceso principal: contrastar representaciones

La prueba sigue bloqueada. Primero se responde una pregunta de representación con la misma regresión logística penalizada y las mismas particiones: ¿la información de `worst` o una PCA aporta generalización respecto de `mean`? Sólo entonces se fija la representación y se comparan algoritmos. La clase positiva es M y el umbral es 0.50.

Tabla 4: Ablación de representación: media CV repetida 5×3 (EE para sensibilidad y AUROC)

Representación	Sens.	Espec.	Bal. acc.	AUROC	EE sens.	EE AUROC
Mean + worst	0.953	0.991	0.972	0.993	0.008	0.002
Todas sin PCA	0.949	0.994	0.971	0.994	0.007	0.002
Todas + PCA (90% var.)	0.925	0.995	0.960	0.994	0.009	0.002
Sólo mean	0.893	0.973	0.933	0.983	0.013	0.002



Decisión del proceso principal. Se fija **Mean + worst** porque obtiene la mayor sensibilidad media en CV repetida; AUROC y balanced accuracy resuelven empates. Así, `worst` y PCA no se incorporan por intuición ni se excluyen por correlación: su aporte se contrasta en datos no vistos dentro de cada fold. Esta decisión no usa la prueba final.

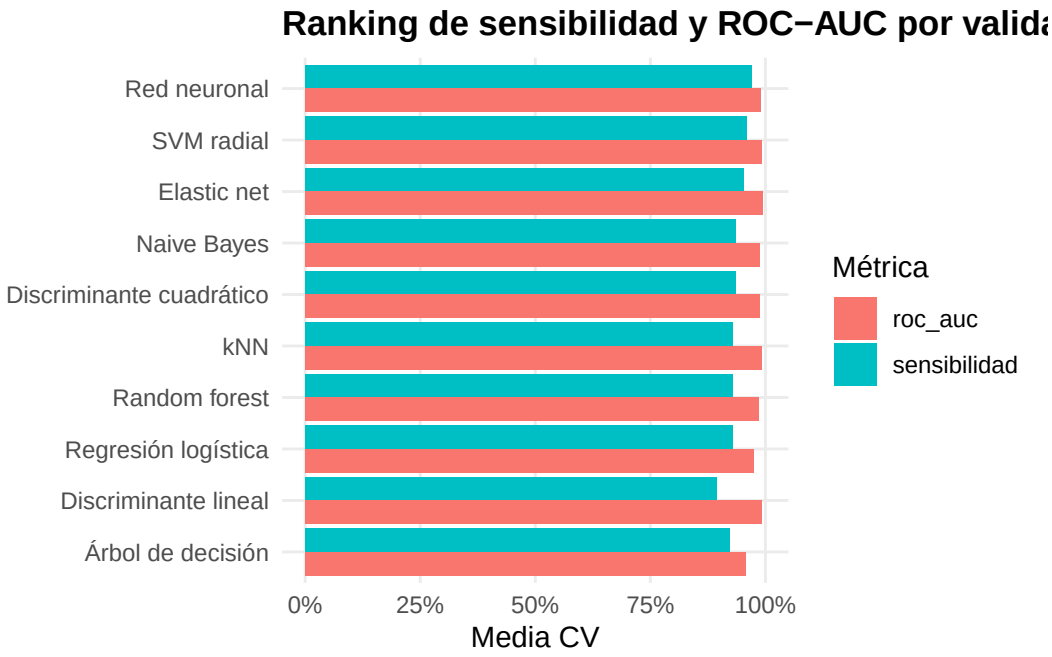
8 8. Proceso principal: comparación de algoritmos

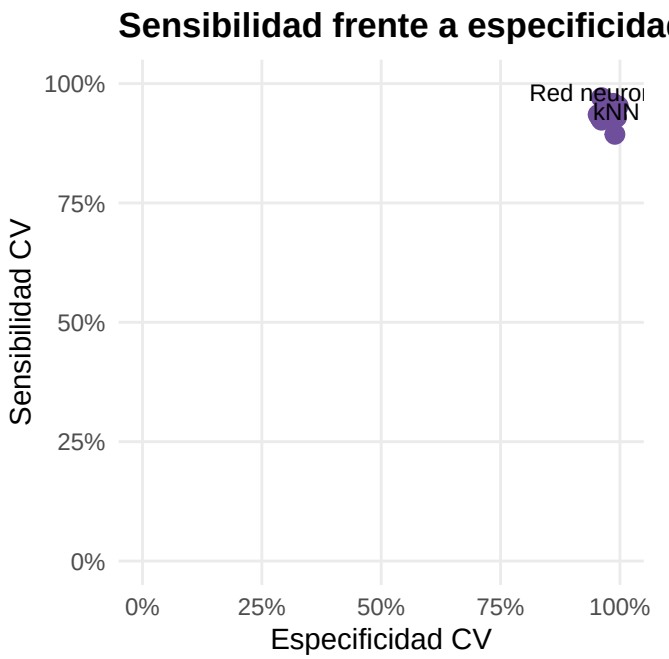
Tabla 5: Comparación de 10 modelos: media CV estratificada (5 folds); la regla mayoritaria se muestra abajo como referencia

Modelo	Sens.	Espec.	Bal. acc.	AUROC	Seg.
Red neuronal	0.971	0.961	0.966	0.990	0.590
SVM radial	0.959	0.986	0.972	0.991	1.236
Elastic net	0.953	0.996	0.975	0.994	0.561
Naive Bayes	0.935	0.954	0.945	0.987	0.584
Discriminante cuadrático	0.935	0.961	0.948	0.987	0.526
kNN	0.929	0.993	0.961	0.993	0.671
Regresión logística	0.929	0.958	0.944	0.974	0.658
Random forest	0.929	0.972	0.950	0.985	1.196
Árbol de decisión	0.923	0.961	0.942	0.958	0.559
Discriminante lineal	0.894	0.989	0.942	0.992	0.536

Tabla 6: Referencia: predecir siempre benigno (no participa en el ranking)

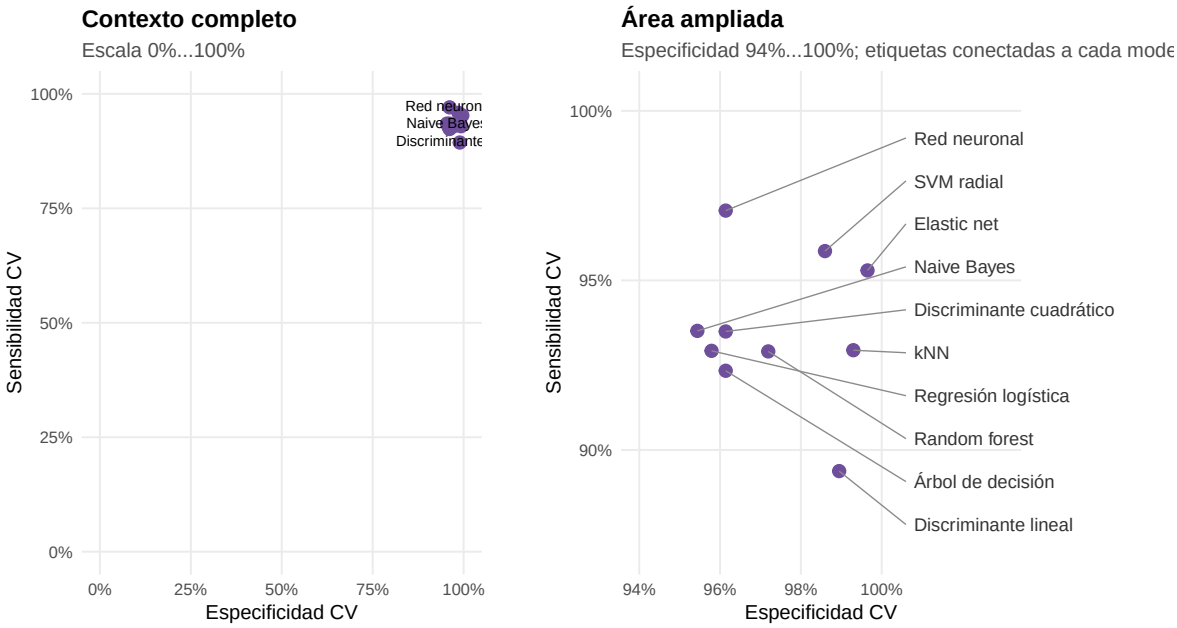
Referencia	Sens.	Espec.	Bal. acc.	Accuracy	AUROC
Regla mayoritaria (B)	0	1	0.5	0.628	0.5





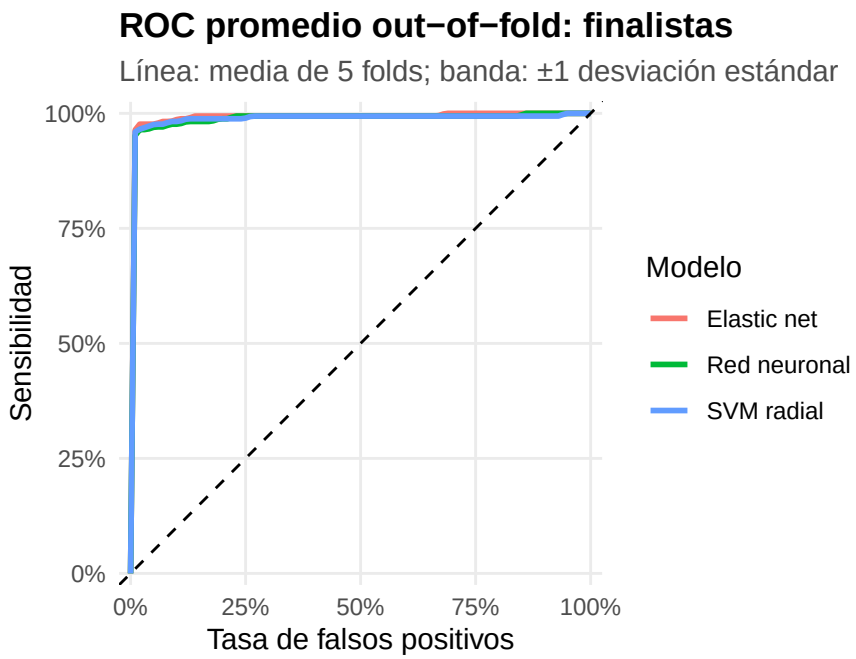
8.1 Zoom para inspeccionar el área concentrada

Los dos paneles usan exactamente los mismos resultados CV. El panel ampliado declara límites recortados: sirve para comparar diferencias pequeñas, no para sustituir la escala completa.



Lectura del zoom. Los paneles alineados separan contexto y detalle sin ocultar los límites de los ejes. La tabla CV conserva los valores exactos; el zoom sólo facilita comparar diferencias pequeñas entre modelos.

Lectura de comparación CV. Red neuronal encabeza la sensibilidad media (97.1%) y por eso entra primero al grupo de finalistas. El ranking muestra que sensibilidad y ROC-AUC no siempre ordenan igual los modelos; el diagrama sensibilidad-especificidad permite observar ese coste. Los puntos más cercanos a la esquina superior derecha equilibran mejor detección de malignos y control de falsos positivos, aunque la sensibilidad conserva prioridad en este análisis académico.



Lectura ROC out-of-fold. Las curvas se calculan con predicciones de folds no vistos por cada ajuste, por lo que no son una curva ajustada sobre los mismos casos usados para entrenar. Curvas más próximas a la esquina superior izquierda indican mejor discriminación; las bandas reflejan variación entre folds. El solapamiento parcial de bandas aconseja no declarar ganador clínico sólo por diferencias visuales pequeñas.

8.2 Ajuste y elección del campeón en entrenamiento

Los tres finalistas se seleccionan por sensibilidad media CV; los empates se resuelven por ROC-AUC y balanced accuracy. El ajuste usa una validación cruzada estratificada de 3 folds y una grilla deliberadamente acotada, adecuada al tamaño del conjunto y a una comparación académica. Se optimizan parámetros propios de cada algoritmo cuando existen; la representación ya fue fijada en la etapa anterior. El campeón se elige aquí, antes de abrir la prueba.

```
maximum number of iterations reached 0.0005051148 -0.0005051166maximum number of iterations r
```

Tabla 7: Finalistas tras ajuste: validación cruzada estratificada de 3 folds

Finalista	Sens.	Espec.	Bal. acc.	AUROC
Red neuronal	0.935	0.954	0.945	0.985
SVM radial	0.243	0.996	0.620	0.962

Finalista	Sens.	Espec.	Bal. acc.	AUROC
Elastic net	0.935	0.947	0.941	0.988

Tabla 8: Evaluación única de la prueba reservada: campeón elegido exclusivamente por CV

Campeón	Sens.	Espec.	Prec.	Bal. acc.	Accuracy	AUROC
Elastic net	0.953	0.986	0.976	0.97	0.974	0.978

```
          Truth
Prediction  M  B
         M 41  1
         B  2 71
```

Lectura del ajuste. El campeón es **Elastic net**, elegido por sensibilidad repetida CV (93.5%), con AUROC y balanced accuracy como controles. Sólo después se abre la prueba: alcanza sensibilidad de 95.3%. No se busca un ganador nuevo en prueba; hacerlo convertiría la prueba en otra etapa de selección y sobreestimaría el resultado.

Resultado predictivo. Los finalistas se eligieron sin consultar la prueba reservada. La sensibilidad es el criterio principal, pero la tabla final mantiene especificidad, balanced accuracy y ROC-AUC para mostrar el coste de cualquier mejora. Estos resultados son académicos y no validan uso clínico, generalización externa ni umbrales de decisión reales.

9 9. Hallazgos y conclusiones

9.1 Hallazgos sobre los datos

1. **Calidad y cobertura.** La fuente aporta 569 masas mamarias, 30 mediciones nucleares y un diagnóstico observado para cada caso. La única columna descartada de la vista analítica estaba completamente vacía por el delimitador final. No se encontraron faltantes, registros idénticos ni IDs duplicados; por tanto, el análisis no requirió imputación, deduplicación ni eliminación de observaciones.
2. **Distribución del diagnóstico.** Se observan 357 casos benignos y 212 malignos. El predominio benigno es moderado, de modo que accuracy no basta para evaluar el desempeño: detectar malignos requiere revisar sensibilidad junto con especificidad y balanced accuracy.

3. **Señal descriptiva por características.** Los boxplots, el forest plot y el AUROC univariado convergen en un patrón: las mediciones de tamaño, perímetro, área y concavidad tienden a ser mayores en el grupo maligno. Entre las medidas promedio, Concave Points presenta la mayor separación estandarizada; de forma aislada, perimeter_worst obtiene el AUROC más alto (0.978) en entrenamiento. Existe, sin embargo, solapamiento entre diagnósticos, por lo que ninguna medición aislada constituye una regla suficiente.

9.2 Hallazgos sobre estructura y representación

4. **Redundancia informativa.** Las mediciones no aportan información completamente independiente: 28 de 435 pares presentan correlación absoluta igual o superior a 0.85. La relación más intensa se observa entre perimeter_mean y radius_mean (0.998). Esto explica por qué los coeficientes lineales y las importancias de un bosque pueden repartirse entre variables similares.

5. **PCA como síntesis, no como decisión automática.** Los primeros dos componentes resumen 63.7% de la variabilidad total; se requieren 5 componentes para alcanzar 80% y 7 para 90%. PCA hace visible una estructura compartida y una separación parcial de diagnósticos, pero la proyección no muestra grupos clínicos puros. Por ello, PCA se trató como una hipótesis que debía ser contrastada, no como una simplificación impuesta.

6. **Representación elegida por evidencia validada.** La ablación comparó `mean`, `mean + worst`, las 30 variables y una versión PCA bajo las mismas particiones. La representación seleccionada fue **Mean + worst** por su sensibilidad media CV, usando AUROC y balanced accuracy para desempatar. En consecuencia, la presencia de correlación no llevó a eliminar variables arbitrariamente: la decisión se basó en desempeño fuera de cada fold.

9.3 Conclusión predictiva

7. **Comparación de algoritmos.** Diez clasificadores se compararon con validación cruzada estratificada. La regla de clase mayoritaria se mantuvo como referencia y evidencia que una accuracy razonable puede coexistir con sensibilidad nula para malignos. El ranking mostró que sensibilidad, especificidad y AUROC no siempre favorecen al mismo modelo; por eso la selección no se redujo a una única métrica.

8. **Modelo final del estudio.** Tras el ajuste de los tres finalistas, **Elastic net** fue elegido exclusivamente con datos de entrenamiento por sensibilidad CV de 93.5%, con AUROC de 0.988 y balanced accuracy de 0.941. En la única evaluación sobre la prueba reservada, obtuvo sensibilidad de 95.3%, especificidad de 98.6%, balanced accuracy de 97.0% y AUROC de 0.978.

En conjunto, el proyecto demuestra que las características nucleares contienen una señal predictiva fuerte y estructurada para distinguir los diagnósticos de este conjunto. La contribución principal no es sólo el desempeño final: es haber convertido una exploración de diferencias, redundancia y reducción de dimensión en una decisión reproducible sobre representación y modelo, manteniendo la prueba final fuera de todas las decisiones previas.

9.4 Renderizado

Desde la raíz del proyecto:

```
quarto render notebook/analisis_integral.qmd --to html
quarto render notebook/analisis_integral.qmd --to pdf
mv notebook/analisis_integral.pdf report/analisis_integral.pdf
```

El primer comando deja `analisis_integral.html` junto al notebook. Los dos últimos generan y ubican el PDF final en `report/`.